

LAPORAN TUGAS AKHIR
STATISTIKA DAN PROBABILITAS
STUDI KASUS PREDIKSI BIAYA ASURANSI KESEHATAN MENGGUNAKAN
KNN, RANDOM FORREST, DAN ADABOOST

Dosen Pengampu : Andi Hendra, Ph.d



Disusun oleh:

Nur Aisyah

F55123037

PRODI S1 TEKNIK INFORMATIKA
JURUSAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS TADULAKO
TAHUN
2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Asuransi kesehatan merupakan salah satu instrumen penting dalam sistem perlindungan sosial yang bertujuan membantu individu menanggung biaya perawatan medis. Perusahaan asuransi kesehatan menghadapi tantangan dalam menetapkan premi yang adil dan kompetitif, sekaligus memastikan keberlanjutan bisnis. Penetapan premi yang tepat memerlukan pemahaman mendalam mengenai faktor-faktor yang memengaruhi biaya kesehatan setiap individu.

Perkembangan teknologi kecerdasan buatan dan machine learning telah membuka peluang besar dalam berbagai bidang, termasuk industri asuransi. Dengan memanfaatkan data historis, algoritma machine learning mampu mengenali pola-pola kompleks yang menghubungkan karakteristik individu dengan biaya asuransi kesehatan yang mereka tanggung.

Dataset Medical Cost Personal menyediakan informasi terkait biaya asuransi kesehatan yang dibayarkan oleh 1.338 individu beserta karakteristik mereka, seperti usia, jenis kelamin, indeks massa tubuh (BMI), jumlah anak tanggungan, status merokok, dan wilayah tempat tinggal. Dataset ini menjadi dasar pengembangan model prediksi yang diharapkan dapat membantu perusahaan asuransi dalam mengestimasi biaya yang harus ditanggung oleh setiap nasabah.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam praktikum ini adalah:

1. Bagaimana pengaruh faktor usia, jenis kelamin, kebiasaan merokok, BMI, dan wilayah tempat tinggal terhadap biaya asuransi kesehatan individu?
2. Model machine learning manakah yang paling akurat dalam memprediksi biaya asuransi kesehatan berdasarkan dataset Medical Cost Personal?

1.3 Tujuan

Tujuan dari praktikum ini adalah:

1. Menganalisis pengaruh berbagai faktor (usia, jenis kelamin, merokok, BMI, wilayah) terhadap biaya asuransi kesehatan.
2. Membangun model prediksi biaya asuransi kesehatan menggunakan algoritma K-Nearest Neighbor (KNN), Random Forest, dan Boosting (AdaBoost).

3. Mengevaluasi dan membandingkan performa ketiga model tersebut menggunakan metrik Root Mean Squared Error (RMSE).

1.4 Manfaat

Hasil praktikum ini diharapkan dapat memberikan manfaat bagi perusahaan asuransi kesehatan dalam menentukan harga premi yang tepat dan adil berdasarkan karakteristik nasabah. Selain itu, model prediksi yang dibangun dapat digunakan sebagai alat bantu pengambilan keputusan yang lebih objektif dan berbasis data dalam industri asuransi.

BAB II

TEORI DASAR

2.1 Machine Learning

Machine learning adalah cabang dari kecerdasan buatan yang memungkinkan komputer untuk belajar dari data tanpa harus diprogram secara eksplisit. Dalam konteks prediksi biaya asuransi, machine learning digunakan untuk membangun model regresi yang mampu memprediksi nilai numerik (biaya) berdasarkan sekumpulan fitur atau variabel masukan.

2.2 Dataset Medical Cost Personal

Medical Cost Personal Datasets merupakan dataset publik yang berisi informasi biaya asuransi kesehatan individu. Dataset ini memiliki 1.338 baris data dengan 7 variabel sebagai berikut:

- age: Usia individu dalam satuan tahun.
- sex: Jenis kelamin individu (male/female).
- bmi: Body Mass Index, indikator berat badan ideal seseorang (kg/m^2).
- children: Jumlah anak yang diasuransikan.
- smoker: Status merokok individu (yes/no).
- region: Wilayah tempat tinggal individu di Amerika Serikat.
- charges: Biaya asuransi kesehatan yang dibebankan kepada individu (variabel target).

2.3 Eksplorasi Data Analisis (EDA)

Eksplorasi Data Analisis (EDA) adalah proses investigasi awal terhadap data untuk menemukan pola, anomali, dan wawasan menggunakan teknik statistik dan visualisasi. EDA terdiri dari dua jenis analisis, yaitu Univariate Analysis (analisis satu variabel) dan Multivariate Analysis (analisis hubungan antar variabel).

2.4 Penanganan Outlier dengan Metode IQR

Outlier adalah data yang berada jauh di luar distribusi normal sekumpulan data. Metode Interquartile Range (IQR) digunakan untuk mendeteksi dan menghapus outlier. IQR dihitung sebagai selisih antara kuartil ketiga (Q_3) dan kuartil pertama (Q_1). Data yang berada di luar batas bawah ($Q_1 - 1.5 \times \text{IQR}$) atau batas atas ($Q_3 + 1.5 \times \text{IQR}$) dianggap sebagai outlier.

2.5 One-Hot Encoding

One-Hot Encoding adalah teknik encoding yang digunakan untuk mengubah variabel kategorikal menjadi variabel numerik. Setiap kategori direpresentasikan sebagai kolom

baru bernilai biner (0 atau 1). Teknik ini diperlukan karena sebagian besar algoritma machine learning hanya menerima masukan berupa data numerik.

2.6 Standarisasi Data

Standarisasi adalah proses transformasi data numerik sehingga memiliki nilai rata-rata (mean) = 0 dan standar deviasi = 1. Proses ini dilakukan menggunakan StandardScaler dari library scikit-learn. Standarisasi penting untuk memastikan bahwa fitur-fitur dengan skala berbeda tidak mendominasi proses pelatihan model.

2.7 Algoritma K-Nearest Neighbor (KNN)

K-Nearest Neighbor (KNN) adalah algoritma machine learning yang sederhana namun efektif untuk tugas klasifikasi maupun regresi. Algoritma ini bekerja dengan mencari k data training terdekat dari suatu data uji berdasarkan metrik jarak (umumnya jarak Euclidean), kemudian mengambil rata-rata nilai target dari k tetangga terdekat tersebut sebagai hasil prediksi. Nilai k yang digunakan dalam percobaan ini adalah 5.

2.8 Algoritma Random Forest

Random Forest adalah algoritma ensemble learning yang membangun sejumlah besar pohon keputusan (decision tree) secara paralel dengan menggunakan sampel data acak (bootstrap sampling) dan subset fitur yang dipilih secara acak pada setiap node. Hasil prediksi akhir diperoleh dari rata-rata prediksi seluruh pohon. Keunggulan Random Forest adalah kemampuannya mengatasi overfitting dan menangani dataset berdimensi tinggi.

2.9 Algoritma AdaBoost

AdaBoost (Adaptive Boosting) adalah algoritma ensemble learning yang membangun model secara berurutan. Setiap model baru difokuskan untuk memperbaiki kesalahan prediksi model sebelumnya dengan memberikan bobot lebih tinggi pada data yang salah diprediksi. Hasil akhir merupakan kombinasi berbobot dari seluruh model yang dibangun secara iteratif.

2.10 Metrik Evaluasi RMSE

Root Mean Squared Error (RMSE) adalah metrik evaluasi yang umum digunakan untuk permasalahan regresi. RMSE mengukur rata-rata besarnya selisih antara nilai prediksi dan nilai aktual dalam satuan yang sama dengan variabel target. Formula RMSE adalah sebagai berikut:

$$RMSE = \sqrt{(1/n) \times \sum (y_{pred} - y_{true})^2}$$

Semakin kecil nilai RMSE, semakin akurat model dalam memprediksi nilai target. RMSE sensitif terhadap outlier karena menggunakan perhitungan kuadrat dari selisih prediksi.

BAB III

LANGKAH KERJA

3.1 Persiapan Data

Dataset dimuat dari file CSV menggunakan library Pandas. Berikut adalah kode yang digunakan:

```
import pandas as pd

data = pd.read_csv('/insurance.csv')

data.head()
```

Dataset ini terdiri dari 1.338 baris data dengan 7 kolom. Variabel numerik meliputi age, bmi, dan charges, sedangkan variabel kategorikal meliputi sex, smoker, dan region.

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520


3.2 Penanganan Outlier

Outlier dideteksi menggunakan visualisasi boxplot pada variabel numerik. Ditemukan adanya outlier pada variabel bmi dan charges.

```
import seaborn as sns
import matplotlib.pyplot as plt

# Menampilkan boxplot untuk seluruh kolom
fig, axes = plt.subplots(nrows=3, ncols=1, figsize=(5, 10))
for i, column in enumerate(numerical_features):
    sns.boxplot(ax=axes[i], x=data[column], palette='Set3')
    axes[i].set_xlabel(column)

plt.show()
```



Selanjutnya, outlier dihapus menggunakan metode IQR

```
Q1 = data.quantile(0.25)
Q3 = data.quantile(0.75)
IQR=Q3-Q1
data=data[~((data<(Q1-1.5*IQR))|(data>(Q3+1.5*IQR))).any(axis=1)]
```

/opt/conda/lib/python3.7/site-packages/ipykernel_launcher.py:4: FutureWarning: Automatic reindexing on DataFrame vs Series comparisons is deprecated and will raise ValueError in a future version. after removing the cwd from sys.path.




3.3 Exploratory Data Analysis (EDA)


3.3.1 Univariate Analysis

```
import pandas as pd
import matplotlib.pyplot as plt

def plot_categorical(data, categorical_features):
    for feature in categorical_features[:3]:
        count = data[feature].value_counts()
        percent = 100*data[feature].value_counts(normalize=True)
        df = pd.DataFrame({'jumlah sampel':count, 'persentase':percent.round(1)})
        print(df)
        count.plot(kind='bar', title=feature)
        plt.show()
    plot_categorical(data, categorical_features)
```

```
data.hist(bins=50, figsize=(10,10))  
plt.show()
```





Analisis univariat dilakukan untuk memahami distribusi masing-masing variabel secara individual. Berikut adalah temuan utama:

- Variabel sex: Distribusi hampir seimbang, dengan sedikit dominasi jenis kelamin female.
- Variabel smoker: Mayoritas individu adalah non-perokok, sehingga rata-rata biaya asuransi yang ditampilkan cenderung lebih rendah.
- Variabel region: Mayoritas individu berasal dari wilayah northwest.

Distribusi variabel numerik (age, bmi, charges) bersifat menceng kanan (right-skewed), yang menunjukkan adanya beberapa individu dengan nilai charges yang sangat tinggi.





3.3.2 Multivariate Analysis

```
cat_features = data.select_dtypes(include='object').columns.to_list()

for col in cat_features:
    sns.catplot(x=col, y="charges", kind="bar", dodge=False, height = 4, aspect = 3, data=data, palette="Set3")
    plt.title("Rata-rata 'charges' Relatif terhadap - {}".format(col))
```

```
plt.figure(figsize=(10, 8))
correlation_matrix = data.corr().round(2)

# Untuk menge-print nilai di dalam kotak, gunakan parameter anot=True
sns.heatmap(data=correlation_matrix, annot=True, cmap='coolwarm', linewidths=0.5, )
plt.title("Correlation Matrix untuk Fitur Numerik ", size=20)
```



Analisis multivariat digunakan untuk memahami hubungan antar variabel. Hasil analisis menunjukkan:

- Individu berjenis kelamin male memiliki rata-rata biaya asuransi lebih tinggi dibandingkan female.
- Perokok memiliki rata-rata biaya asuransi yang jauh lebih tinggi dibandingkan non-perokok.
- Wilayah southeast memiliki rata-rata biaya asuransi tertinggi.
- Berdasarkan matriks korelasi, variabel bmi dan children memiliki korelasi yang sangat kecil (≤ 0.2) dengan charges, sehingga kedua variabel tersebut dihapus dari analisis lebih lanjut.

3.4 Data Preparation

3.4.1 Encoding Fitur Kategori

Variabel kategorikal (sex, smoker, region) diubah menjadi variabel numerik menggunakan One-Hot Encoding:

```
from sklearn.preprocessing import OneHotEncoder

def one_hot_encode(data, columns):
    encoder = OneHotEncoder(handle_unknown='ignore')
    encoded = encoder.fit_transform(data[columns])
    labels = encoder.get_feature_names_out(columns)
    encoded_df = pd.DataFrame(encoded.toarray(), columns=labels)
    data = pd.concat([data.drop(columns, axis=1), encoded_df], axis=1)
    return data

data = one_hot_encode(data, categorical_features)

data.head()
```

	age	charges	sex_female	sex_male	smoker_no	smoker_yes	region_northeast	region_northwest	region_southeast	region_southwest
0	19.0	16884.92400	1.0	0.0	0.0	1.0	0.0	0.0	0.0	1.0
1	18.0	1725.55230	0.0	1.0	1.0	0.0	0.0	0.0	1.0	0.0
2	28.0	4449.46200	0.0	1.0	1.0	0.0	0.0	0.0	1.0	0.0
3	33.0	21984.47061	0.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0
4	32.0	3866.85520	0.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0

3.4.2 Train-Test Split

```
from sklearn.model_selection import train_test_split

X = data.drop(["charges"], axis=1)
y = data["charges"]
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

print(f'Total # of sample in whole dataset: {len(X)}')
print(f'Total # of sample in train dataset: {len(X_train)}')
print(f'Total # of sample in test dataset: {len(X_test)}')
```

Total # of sample in whole dataset: 1064
Total # of sample in train dataset: 851
Total # of sample in test dataset: 213

3.4.3 Standarisasi

Variabel numerik age distandarisasi menggunakan StandardScaler sehingga memiliki mean=0 dan standar deviasi=1:

```
from sklearn.preprocessing import StandardScaler

numerical_features = ['age']
scaler = StandardScaler()
scaler.fit(X_train[numerical_features])
X_train[numerical_features] = scaler.transform(X_train.loc[:, numerical_features])
X_train[numerical_features].head()
```

	age
51	-1.329346
869	-1.045445
613	-0.406669
630	0.941860
1126	1.083810

3.5 Pemodelan

Tiga algoritma machine learning digunakan untuk membangun model prediksi:

3.5.1 K-Nearest Neighbor (KNN)

```
from sklearn.neighbors import KNeighborsRegressor
from sklearn.metrics import mean_squared_error

knn = KNeighborsRegressor(n_neighbors=5)
knn.fit(X_train, y_train)

models.loc['train_mse', 'knn'] = mean_squared_error(y_pred = knn.predict(X_train), y_true=y_train)
```

3.5.2 Random Forest

```
from sklearn.ensemble import RandomForestRegressor

# buat model prediksi
RF = RandomForestRegressor(n_estimators=100, max_depth=35, random_state=123, n_jobs=-1)
RF.fit(X_train, y_train)

models.loc['train_mse', 'RandomForest'] = mean_squared_error(y_pred=RF.predict(X_train), y_true=y_train)
```

3.5.3 AdaBoost

```
from sklearn.ensemble import AdaBoostRegressor

boosting = AdaBoostRegressor(learning_rate=0.05, random_state=55)
boosting.fit(X_train, y_train)

models.loc['train_mse', 'Boosting'] = mean_squared_error(y_pred=boosting.predict(X_train), y_true=y_train)
```

3.6 Evaluasi Model

```
# Buat variabel mse yang isinya adalah dataframe nilai mse data train dan test pada masing-masing algoritma
mse = pd.DataFrame(columns=['train', 'test'], index=['KNN', 'RF', 'Boosting'])

# Buat dictionary untuk setiap algoritma yang digunakan
model_dict = {'KNN': knn, 'RF': RF, 'Boosting': boosting}

# Hitung Mean Squared Error masing-masing algoritma pada data train dan test
for name, model in model_dict.items():
    mse.loc[name, 'train'] = mean_squared_error(y_true=y_train, y_pred=model.predict(X_train))/1e3
    mse.loc[name, 'test'] = mean_squared_error(y_true=y_test, y_pred=model.predict(X_test))/1e3

# Panggil mse
mse
```

	train	test
KNN	33867.635795	43724.319886
RF	23051.135798	45302.143621
Boosting	40740.95087	41147.97909

Evaluasi model dilakukan menggunakan metrik Mean Squared Error (MSE) pada data training dan data testing. Hasil evaluasi dirangkum dalam tabel berikut:

Model	MSE Train	MSE Test
KNN	Sedang	Sedang
Random Forest	Rendah (Terbaik)	Sedang
AdaBoost	Sedang	Rendah (Terbaik)

Dari hasil evaluasi, Random Forest menunjukkan performa terbaik pada data training dengan MSE paling rendah. Namun, pada data testing, model AdaBoost (Boosting) menghasilkan MSE paling rendah, menandakan kemampuan generalisasi yang lebih baik. Dengan demikian, AdaBoost dipilih sebagai model terbaik untuk prediksi biaya asuransi kesehatan pada data baru.

3.7 Uji Prediksi

```
prediksi = X_test.iloc[:1].copy()
pred_dict = {'y_true':y_test[:1]}
for name, model in model_dict.items():
    pred_dict['prediksi_'+name] = model.predict(prediksi).round(3)

pd.DataFrame(pred_dict)
```

	y_true	prediksi_KNN	prediksi_RF	prediksi_Boosting
778	5934.3798	5937.69	5956.881	8798.411

Pengujian dilakukan pada satu sampel data uji. Nilai aktual (y_true) untuk sampel tersebut adalah sebesar 5934.38. Berikut adalah hasil prediksi dari masing-masing model:

- KNN: 5937.69 (paling mendekati nilai aktual)
- Random Forest: Hasil prediksi berbeda lebih jauh dari nilai aktual.
- AdaBoost: Hasil prediksi berbeda lebih jauh dari nilai aktual.

Pada contoh pengujian tunggal ini, model KNN memberikan prediksi yang paling mendekati nilai aktual dengan selisih hanya 3.31.

BAB 4

PENUTUP

4.1 Kesimpulan

Berdasarkan seluruh rangkaian percobaan yang telah dilakukan, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Faktor-faktor yang paling berpengaruh terhadap biaya asuransi kesehatan adalah status merokok (smoker), usia (age), dan wilayah tempat tinggal (region). Perokok memiliki rata-rata biaya asuransi yang jauh lebih tinggi dibandingkan non-perokok. Individu berjenis kelamin male juga cenderung memiliki biaya asuransi lebih tinggi. Wilayah southeast menunjukkan rata-rata biaya asuransi tertinggi di antara wilayah lainnya.
2. Variabel BMI dan jumlah anak (children) terbukti memiliki korelasi yang sangat kecil dengan biaya asuransi (≤ 0.2), sehingga dieliminasi dari model untuk meningkatkan efisiensi komputasi dan mencegah overfitting.
3. Dari ketiga model yang diuji, Random Forest memberikan performa terbaik pada data training, sedangkan AdaBoost (Boosting) memberikan performa terbaik pada data testing berdasarkan nilai MSE terkecil. Hal ini menunjukkan bahwa AdaBoost memiliki kemampuan generalisasi yang lebih baik dan lebih cocok untuk memprediksi data baru.
4. Pada pengujian sampel tunggal, model KNN justru memberikan prediksi paling mendekati nilai aktual, dengan selisih hanya 3.31 dari nilai aktual sebesar 5934.38. Hal ini menunjukkan bahwa pemilihan model terbaik perlu mempertimbangkan baik metrik agregat (MSE keseluruhan) maupun performa pada kasus individual.

4.2 Saran

Untuk meningkatkan kualitas model prediksi, beberapa saran yang dapat diterapkan pada penelitian selanjutnya antara lain:

1. Melakukan hyperparameter tuning yang lebih sistematis menggunakan teknik seperti Grid Search atau Random Search untuk mendapatkan kombinasi parameter optimal pada setiap algoritma.

2. Mengeksplorasi algoritma-algoritma lain seperti Gradient Boosting, XGBoost, atau neural network untuk membandingkan performanya dengan algoritma yang telah digunakan.
3. Menggunakan teknik cross-validation untuk mendapatkan estimasi performa model yang lebih andal dan tidak bergantung pada satu partisi data tertentu.
4. Memperluas dataset dengan menambahkan lebih banyak fitur yang relevan, seperti riwayat penyakit, frekuensi kunjungan dokter, dan pola gaya hidup, guna meningkatkan akurasi prediksi secara keseluruhan.